

基于机器视觉的晶圆表面缺陷检测方法研究

张金宇¹, 朱立军^{1,2†}, 林紫强¹

(1. 沈阳化工大学计算机科学与技术学院, 辽宁 沈阳 110142; 2. 辽宁省化工过程工业智能化技术重点实验室, 辽宁 沈阳 110142)

摘 要:晶圆作为半导体制造业中重要的原材料,其表面缺陷会影响其制成芯片的质量。为了确保芯片的质量和效率,对晶圆表面的缺陷进行高效、准确、实时的检测具有必要性。本文针对有图案的晶圆表面提出了一种缺陷检测方案,首先,获取晶圆图像并对其做预处理操作,对图像进行光照均衡使其灰度均匀性得到提升;其次,根据晶圆图像纹理的规律性和周期性,设计了图像熵信息与灰度模板匹配相结合的方法提高匹配的准确性,划分出每个小单元格;然后,将划分的单元与模板单元进行差分,使用傅里叶变换设计滤波器去除图像中光学系统畸变影响;最后,通过计算图像离散程度,根据不同区域离散度与全图离散度对比进行缺陷增强。最终实验表明,对于缺陷检测准确率可达93.5%,该方法可以有效地应用于有图案晶圆表面缺陷的检测。

关键词:自动光学检测;熵;灰度模板匹配;傅里叶变换;伽马变换
中图分类号:TP391.41 **文献标识码:**A

Research on Wafer Surface Defect Detection Method Based on Machine Vision

ZHANG Jinyu¹, ZHU Lijun^{1,2†}, LIN Ziqiang¹

(1. Department of Computer Science and Technology, Shenyang University of Chemical Technology, Shenyang, Liaoning 110142, China; 2. Liaoning Provincial Key Laboratory of Intelligent Technology for Chemical Process Industry, Shenyang, Liaoning 110142, China)

Abstract: Wafer, as an important raw material in the semiconductor manufacturing industry, its surface defects can affect the quality of chips produced. In order to ensure the quality of chips and improve production efficiency, it is necessary to conduct efficient, accurate, and real-time detection of surface defects on wafers. This article proposes a surface defect detection scheme for patterned wafers. Firstly, the wafer image is obtained and preprocessed, and the image is illuminated to improve its grayscale uniformity; Secondly, based on the regularity and periodicity of wafer image texture, a method combining image entropy information with grayscale template matching was designed to improve the accuracy of matching, and each small cell was divided; Then, the divided units are differentiated from the template units, and Fourier transform is used to design filters to remove the optical system distortion effects in the image; Finally, by calculating the degree of image dispersion, defect enhancement is performed by comparing the dispersion of different regions with that of the entire image. The final experiment shows that the accuracy of defect detection can reach 93.5%, and this method can be effectively applied to the detection of surface defects on patterned wafers.

Key words: automatic optical inspection; entropy; grayscale template matching; Fourier transform; Gamma transform

收稿日期:2023-11-27

基金项目:辽宁省教育科学研究项目(LJ2020023)

作者简介:张金宇(1999—),男,吉林长春人,硕士,研究方向:图像处理。

† 通信联系人, E-mail: zhulijun@yeah.net

随着信息技术的迅速发展,芯片的制造成为现代社会中不可或缺的核心技术之一。在半导体制造领域^[1],晶圆作为制造芯片的基础材料,其表面的质量在整个生产过程中起着非常重要的作用。然而,芯片的制造工艺流程是一个复杂的过程,晶圆表面可能受到来自各个环节的影响,从而造成晶圆表面出现各种缺陷,如划痕、裂纹、脏污等,导致产品性能下降、电气特性受损甚至完全失效。因此,对晶圆表面的缺陷进行有效的检测具有至关重要的意义。传统的手动检测方法耗时较长,不适合现代大批量生产,而自动光学检测系统^[2]使用运动平台搭配工业线阵扫描相机进行图像获取,应用图像处理技术^[3]能够准确高效地识别缺陷。其在纺织物^[4]和钢材等工业行业广泛应用,已经成为晶圆表面缺陷检测的一种解决方案^[5]。

在晶圆表面缺陷检测中,何睿清等^[6]采用了一种先评估虚焦状态下的晶圆图像的方法,判断是否存在缺陷后再对焦进行检测。Li等^[7]将小波系数分解作为特征,并使用连续水平之间的系数值之差作为权重来区分晶圆表面中的局部缺陷。Tsai等^[8]通过计算小邻域窗口中不同方向的熵,将灰度图像转换为熵图像后进行检测。这两种方法可以有效地检测出太阳能晶片表面的指纹、污染物和锯痕等缺陷。Ko等^[9]通过改进LBP方法选择最优阈值来检测缺陷。Chen等^[10]提出名为WDD-Net的深度学习模型进行缺陷检测。深度学习模型通常需要大量的标记数据进行训练,然而在晶圆生产和工艺加工中很难获得足够的缺陷样本进行学习。

上述的晶圆表面检测方法中,主要关注的是无图案的晶圆硅片。然而,在处理有图案晶圆时,由于复杂的纹理图案受到光学畸变的影响产生了更多的噪声,在检测过程中,需要在排除噪声的干扰的情况下保证缺陷的完整性,避免在消除噪声的过程中削弱缺陷特征,造成把噪声当作缺陷或未检测出缺陷的情况。因此需要设计新的缺陷检测方法。在本文中,先将待检测单元与模板单元差分,将差分后图像灰度映射到不同通道,将灰度变化较大的通道进行自适应阈值分割标记缺陷,针对灰度变化较小缺陷区域设计了一种分块增强图像缺陷的方法,根据其背景图像灰度的离散度与缺陷区域灰度的离散度的差异性设定不同的增强系数,可以更好地去除噪声和增强缺陷。

1. 平台搭建与晶圆图像采集

晶圆表面图像的采集系统由工业线阵扫描相机、光源、反射镜和电机等组件进行构建,以实现高

速、高精度的图像采集,图像采集装置如图1所示。工业线阵扫描相机是图像采集的核心组件之一,以高速连续的方式捕获晶圆表面的图像数据,具有高分辨率,能够在运动中捕获细节丰富的图像,适用于晶圆表面缺陷检测。光源是确保晶圆表面在采集过程中具有足够亮度和均匀照明,适当的照明系统能够减少噪声,确保采集到清晰的图像。反射镜用于将光线引导到相机的图像传感器上,调整到最佳角度和视野进行图像采集。为了实现晶圆的连续采集,使用直线电机驱动晶圆以恒定的速度移动,同时相机持续地获取图像数据,通过设置电机的速度和相机的采集频率,确保采集到的图像没有拉伸或变形,使采集到的图像具有一致的尺寸。最终使用晶圆镜面通过相机来进行成像效果校正,提升图像的均匀性。




图1 运动平台图

2 图像预处理

2.1 晶圆表面单元的划分

2.1.1 改进模板匹配

在一张晶圆上通常包含多个芯片,每个芯片都会进行制造和测试。为了管理和控制芯片的制造和测试过程,晶圆上的芯片都需要有一个明确的标识和定位。因此,需要将晶圆表面每个小单元都划分出来。由于同一晶圆上的单元的长宽都是一样的,采用模板匹配方法从晶圆中心点选取长方形模板图像,并在横纵两个方向进行匹配来确定单元的长度和宽度。模板匹配分为基于灰度和基于特征的匹配方法,基于灰度的模板匹配方法适用于简单的、不受变形和旋转影响较大的情况,而基于特征的方法适用于对光照、噪声、变形和旋转更具有鲁棒性的应用,但是基于特征的匹配方法通常需要进行复杂的特征提取和匹配过程,因此计算复杂度较高,由于预处理后的晶圆表面图像光照均匀和晶圆表面纹理复杂,所以选用基于灰度的模板匹配方法。对于随机选择模板会有匹配错误的情况,加入图像熵来选取模板图像和进行匹配计算从而提高匹配准确性。

2.1.2 图像熵值

图像熵值用于衡量图像中每个灰度级别的不确定性或混乱程度。如果一个图像的灰度级别分布均匀,那么图像的熵值会较高,因为在不同的灰度级别之间存在更多的不确定性。相反,如果图像的灰度级别分布不均匀,即某些灰度级别出现频率较高,而其他灰度级别出现频率较低,那么图像的熵值会较低。通常较高熵值的区域通常对应于边界、纹理或复杂的图像区域,而较低熵的区域可能对应于颜色单一的区域,图像熵的计算公式为:

$$H(x) = \sum_{i=0}^{i=255} p(i) \log_2 p(i) \quad (1)$$

$H(x)$ 为计算后得出的图像熵值, $p(i)$ 是每个灰度级别 i 的相对频率。如图 2(a) 所示,选取合适大小的区域,在圆心附近使用图像熵值最小的图像为模板图,选择一个在灰度变化小的图像作为模板,以提高匹配的准确性,再将图像熵值与图像灰度差值结合计算来进行模板匹配,改进公式为:

$$D(i, j) = \frac{1}{M \cdot N} \sum_{s=1}^M \sum_{t=1}^N |S(i+s-1, j+t-1) - T(s, t)| \cdot H(x) \quad (2)$$

根据式(1)和式(2)计算图像熵值来选取模板图像,从而进行模板匹配大大提高了匹配的准确性,在图像横纵两个方向上进行模板选取与匹配,得出单元格的长度和宽度之后进行晶圆单元划分,如图 2(b) 所示。最后分割出晶圆的每个单元格,如图 2(c) 所示。根据与无缺陷模板单元差分后进行图像处理和缺陷检测。

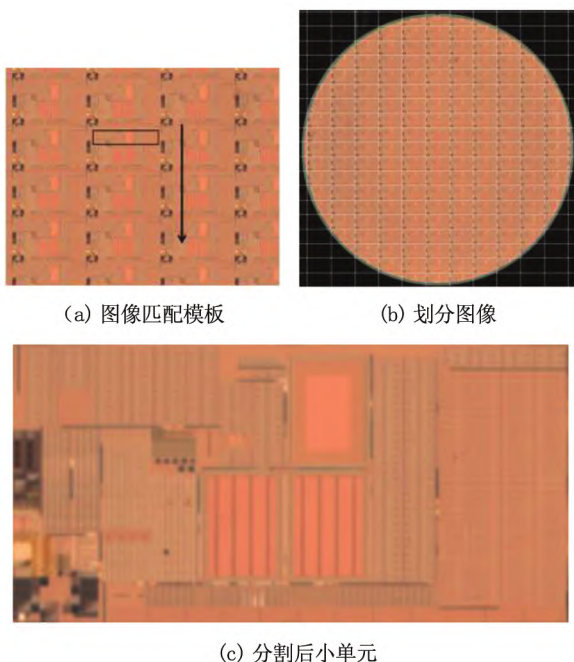


图 2 晶圆划分图

3 晶圆缺陷检测算法

本文提出的基于晶圆表面缺陷检测算法有以下步骤。

1) 图像通道分离。对划分完的晶圆图像与模板图转换为灰度图后进行差分,将差分后的灰度图像进行彩色映射,然后将 RGB 三通道分离, RG 为高灰度映射区域,其中缺陷对比度较高,无噪声影响。

2) 晶圆图像去除噪声处理。其中低灰度的 B 通道包含大量的噪声以及缺陷,对其进行傅里叶变换,设计对应的滤波方法去除条纹噪声和进行背景模糊操作。

3) 晶圆图像增强处理。计算去除噪声后的整张图像的离散度,再将图像分为 7×7 像素大小的小块计算局部离散度,通过比较全局与局部离散度差异,对可能为缺陷的区域针对性增强,降低背景区域的灰度提升对比度。

4) 阈值分割。经过处理后的 RGB 通道,缺陷的灰度对比度明显提高,可以通过自适应阈值分割转换成二值图像,大于阈值灰度的标记为缺陷区域,合并各个通道检测出来的缺陷,得出最终的缺陷检测结果。本文晶圆表面检测方法具体流程如图 3 所示。

将差分后的晶圆图像进一步处理,采用彩色映射方法,将图像中不同的灰度等级映射到对应的彩色通道上,如图 4(a) 所示。然后,通过分离 RGB 通道,可以获得 R 和 G 通道的图像,其中 RG 通道反映了灰度强度较高的区域,如图 4(b) 和 (c) 所示,这些区域可以轻松地检测出缺陷,可以使用自适应阈值分割将缺陷部分标记完成。另一方面,还可以进一步利用 B 通道进行更深入的处理,以检测那些未检出的缺陷的区域,如图 4(d) 所示。

3.1 傅里叶变换去除噪声

光学系统中的个体差异可能会影响色彩还原,导致图像可能出现色差变化。镜头的制造质量差异可能会影响图像的光学畸变,模板图像与检测图像之间的焦距质量与光学畸变存在一定成像差异,需要进行图像处理消除这些影响,本文采用傅里叶变换进行频域处理来消除差分后的噪声纹理。

傅里叶变换用于将图像转化成频率域图像,也称为频谱图,这种方法能够有效地呈现图像中不同频率成分的特征。在频谱图中,中央区域对应低频分量,而从中央向外辐射状地展开则表示高频成分。这由于频率域中的低频部分反映了图像中的平滑或缓慢变化,而高频部分则对应图像中的细节和急剧变化。频率域图像中的亮度表明了频率分

量的强度,更亮的区域代表频率分量在图像中更加显著。如图5(a)和(b)所示,将图像转为频率域进行去噪处理,通过设计滤波掩膜来有选择性地处理图像。如图5(c)所示,将频谱图中对应的高频直

线区域和低频背景区域进行掩膜,以去除背景噪声以及横竖条纹等对检测结果有误判影响的区域,最终去噪处理完成图像如图5(d)所示。

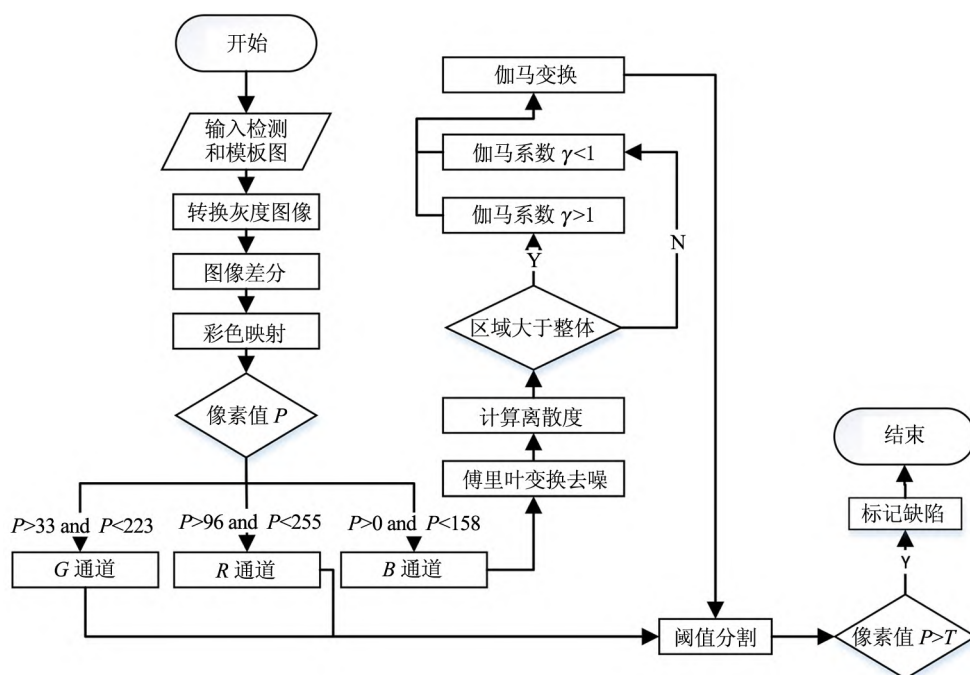


图3 算法流程图




图4 灰度映射后分离 RGB 图

3.2 缺陷增强

图像增强的目的是改善图像的成像效果,针对给定图像有目的地增强图像的整体或局部特性。其在缺陷检测中是为了突出和增强图像中的缺陷,以便进行分析、检测或识别而进行图像增强。这一过程的主要目标是提高缺陷的可视性,使其在图像中更加显著,同时减少背景噪声或干扰的影响,但通常的图像增强方法在增强缺陷的同时,将噪声区域也一起增强了。本文设计了一种方法,通过对整张图像的离散度计算,对比每个区域的变异系数与全局

的变异系数对比选择图像的增强区域与强度,便于排除噪声点对图像的影响,可以更好地平衡图像增强和噪声控制之间的关系,从而提高图像分析的效果。

3.2.1 变异系数计算

计算变异系数是一种用于衡量数据集中变异程度的方法,特别适用于不同数据集之间的比较。它以百分比形式表示,是标准差与均值的比率。以下是计算变异系数的步骤:

1) 计算数据集中数值的均值,公式表示为:

$$\mu = \frac{\sum_{i=1}^N \sum_{j=1}^M X_{(i,j)}}{N \cdot M} \quad (3)$$

2) 计算数据集的标准差,通常用符号 σ 表示。标准差测量了数据集中数据点与均值之间的分散程度,公式表示为:

$$\sigma = \sqrt{\frac{\sum_{i=1}^N \sum_{j=1}^M [X_{(i,j)} - \mu]^2}{N \cdot M}} \quad (4)$$

3) 计算变异系数是标准差与均值之比,通常以百分比表示。公式表示为:

$$CV = \frac{\sigma}{\mu} \cdot 100\% \quad (5)$$

计算得到的变异系数是一个百分比值,描述了数据集中变异的程度。较高的变异系数表示数据

更分散, 较低的变异系数表示数据更集中。变异系数允许比较不同数据集的变异程度, 因为它是相对

于均值的。本文使用的对象为同一张图像, 其中均值选择为图像的全图均值。




图 5 傅里叶变换图

通过比较全局变异系数和局部变异系数, 可以设计一个变化量, 然后应用伽马变换来实现图像增强。将变异系数的比值设置为伽马变换的系数, 从而增强缺陷区域, 降低背景区域的灰度, 从而提高图像的对比度。

3.2.2 伽马变换

伽马变换是一种图像增强的图像处理算法, 用于调整图像的亮度和对比度。通过对图像的每个像素值进行非线性映射来实现这些调整。伽马函数公式表示为:

$$\bar{X}_{(i,j)} = cX_{(i,j)}^{\gamma} \quad X \in [0,1] \quad (6)$$

(1) 当 $\gamma > 1$ 时, 将会减小原来图像的灰度值, 图像会变暗。

(2) 当 $\gamma < 1$ 时, 将会增大原来图像的灰度值, 图像会变亮。

γ 的值根据局部变异系数与全局变异系数的比值决定, 从而增强缺陷区域, 排除噪声区域。图 6(a) 中的是将变异系数可视化, 将计算结果值映射到 0 到 255 的范围, 以便在图像增强过程中使用, 这个方法可以帮助突出图像中的特定区域。如图 6(b) 所示, 将原图像进行本文的分块伽马增强和全局伽马增强, 效果如图 6(c) 和图 6(d) 所示。




图 6 缺陷增强图

表 1 结果统计

类型	图像数	样本数	误检数	准确率
背景纹理	1380	1380	78	0.943
斑点	138	155	12	0.923
大面积脏污	1380	63	3	0.953

4 实验结果分析

为了验证本文晶圆表面缺陷检测算法的准确性, 使用环境为 python3.7 和依赖图像处理库 opencv 进行代码实现, 所采用的硬件为一台搭载 R7-7735H 处理器的 Windows10 计算机。使用工业线扫相机获取半导体设备厂测试晶圆片缺陷图像数据, 将采集的带有图案的晶圆划分成 1380 个小单元进行缺陷检测, 划分后的图像大小为 (346×212) 像素, 表 1 为检测后通过人工对比缺陷统计的结果。

实验中对晶圆图像的以上缺陷进行了分析, 本文算法对去除图像纹理影响效果很好, 在清晰度相差不大的图像能很好地去纹理干扰, 相对于模糊度更高的图像也能得到优化, 在本实验数据集中可以有 94% 的数据很好地除去纹理干扰, 图像中斑点缺陷的检测可以达到 92% 的准确率, 其中小斑点与背景相似或在纹理附近会被纹理去除影响, 导致误检, 大面积脏污基本上都可以检测出来, 准确率在 95%, 对于大面积脏污检测, 图像脏污区域过大和模糊度过高会影响图像配准导致图像缺陷标记错误, 图 7 分别为大面积脏污、划痕缺陷、斑点缺陷和线状脏污的最终检测效果。




图 7 缺陷检测结果图

4.1 实验对比

在本文数据集中使用不同的传统滤波方法进行去除噪声处理后,均不能有效地去除其中的条纹影响,使用图像增强后的纹理噪声与缺陷很难区

分,通过图 8(d3)可以明显看出本文算法可以有效地去除纹理噪声,图像增强可以将缺陷与背景很好地分离。

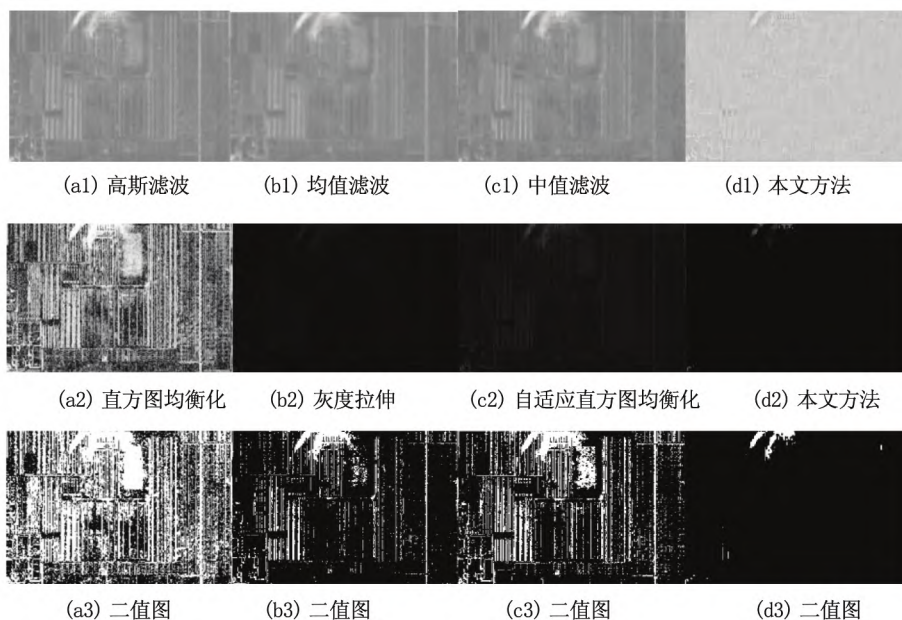


图 8 实验对比图

5 结 论

1) 本文对模板匹配算法进行改进,通过对图像熵值的计算进行模板的选取和模板的匹配计算,这种方法可以提高图像匹配的准确性。通过设计频域滤波方法来实现特定的图像处理,去除图像中横向竖向的噪声线条和背景噪声。

2) 提出了一种基于伽马算法的分块图像增强算法,将原图分割多个小块,通过分块局部区域和

全图离散度的计算与对比,检测每块图像的灰度变化从而选择性加强对比度,通过图像变异系数的大小来判断此区域的灰度变化,对每块区域分别以不同变异系数进行图像增强处理。该算法能避免图像中噪声被增强,增强了图像增强算法对于噪声的鲁棒性。

3) 提出的方法能有效地检测斑点、大面积脏污、明显划痕,对于与背景灰度相近的线状脏污缺陷检测效果不好。

(下转第 122 页)




图 8 不同方法裂纹检测结果 F1 值对比

3 结 论

在风电机组叶片裂纹视觉检测技术的研究中,红外图像边缘检测算法为我们提供了强有力的工具。通过此技术,能够更加准确、有效地检测出叶片表面的微小裂纹,为风电机的维护和检修提供及时、准确的依据。虽然该技术在实验中取得了较好的成果,但仍需要在实际应用中进一步的验证和完善。

参考文献

- [1] 王道累,肖佳威,刘易腾,等. 风电机组叶片损伤检测技术与进展[J]. 中国电机工程学报, 2023, 43(12): 4614—4631.
- [2] 李响,刘书海,肖华平,等. 风电叶片检测机器人设计与运动仿真研究[J]. 现代制造工程, 2023(4): 51—58.
- [3] 蒋兴群,刘波,宋力,等. 基于改进 YOLO-v3 的风力机叶片表面损伤检测识别[J]. 太阳能学报, 2023, 44(3): 212—217.
- [4] 汤占军,孙栋钦,李英娜,等. 改进 FA 优化 SVM 的风机叶片裂纹检测模型[J]. 可再生能源, 2022, 40(9): 1189—1194.
- [5] 刘钦东,罗勇水,张军华,等. 基于 WPT-SVD-KELM 的大型风力机叶片表面裂纹识别方法研究[J]. 太阳能学报, 2023, 44(3): 155—161.
- [6] 基于模型参数辨识的航空发动机风扇叶片裂纹故障诊断[J]. 航空发动机, 2023, 49(1): 115—121.
- [7] 陈雪莲,曾劲,马辉. 基于固定界面法的旋转裂纹叶片动力学特性分析[J]. 航空发动机, 2022, 48(6): 105—109.
- [8] 刘启栋. 基于卷积神经网络的风机叶片损伤检测[J]. 热力发电, 2023, 52(3): 88—93.
- [9] 黄鑫,张小栋,张英杰,等. 基于改进 DBNs 的三维叶尖间隙叶片裂纹诊断方法[J]. 振动. 测试与诊断, 2022, 42(2): 213—219+402.
- [10] 李永乐,骆贵兵,杨辉. 静叶可调轴流式引风机叶片断裂原因分析及对策[J]. 热力发电, 2021, 50(4): 114—119.

(上接第 99 页)

参考文献

- [1] 彭荣超. 晶圆检测设备产业的现状、挑战与发展趋势研究[J]. 中国设备工程, 2023(7): 174—176.
- [2] 郭民,王蕊. AOI 技术在 PCB 缺陷检测中的设计与实现[J]. 测控技术, 2016, 35(12): 127—130.
- [3] 程锦锋,方贵盛,高惠芳. 表面缺陷检测的机器视觉技术研究进展[J]. 计算机应用研究, 2023, 40(4): 967—977.
- [4] 方亮泰,董子靖,朱文博,等. 织物表面缺陷检测的研究进展[J]. 毛纺科技, 2023, 51(4): 94—101.
- [5] MA J, ZHANG T, YANG C, et al. Review of wafer surface defect detection methods[J]. Electronics, 2023, 12(8): 1787.
- [6] 何睿清,周鑫宇,张慧,等. 基于离焦图像的晶圆表面缺陷检

测[J]. 组合机床与自动化加工技术, 2023(7): 110—113, 118.

- [7] LI W C, TSAI D M. Wavelet-based defect detection in solar wafer images with inhomogeneous texture[J]. Pattern Recognition, 2012, 45(2): 742—756.
- [8] TSAI D M, LUO J Y. Mean shift-based defect detection in multicrystalline solar wafer surfaces[J]. IEEE Transactions on Industrial Informatics, 2010, 7(1): 125—135.
- [9] KO J S, RHEEM J Y. Defect detection of polycrystalline solar wafers using local binary mean[J]. The International Journal of Advanced Manufacturing Technology, 2016, 82: 1753—1764.
- [10] CHEN X, CHEN J, HAN X, et al. A light-weighted CNN model for wafer structural defect detection[J]. IEEE Access, 2020, 8: 24006—24018.